




Análisis y exploración de datos

Trabajo Práctico 1

Alumno: Micaela Belén Dominguez

Profesor: Martín Ivan Pasztetnik

Análisis y exploración de datos

Trabajo Integrador

Parte 1: Excel para Análisis de Datos

1.1 Objetivo

Construir una tabla consolidada de órdenes a partir de múltiples fuentes de datos, aplicando left joins, limpieza y transformación, para responder preguntas de análisis mediante tablas dinámicas y gráficos.

1.2 Archivos

Los archivos que se utilizaron para la primera parte son clientes.csv, ordenes.csv, envios.csv, items_orden.csv.

1.3 Carga y exploración

Se importaron los cuatro datasets en Power Query y se relevaron tipos de datos, valores nulos, inconsistencias de texto y formatos de fecha. Los problemas detectados fueron:

- **clientes.csv:** fecha_alta con tres formatos distintos, segmento con mayúsculas inconsistentes, email con 518 nulos y telefono con 1.094 nulos tipado como decimal.
- **ordenes.csv:** fecha_orden con múltiples formatos, ciudad_envio, canal_venta y estado_orden con normalización de texto inconsistente.
- **envios.csv:** fecha_envio y fecha_entrega con formatos mixtos, empresa_logistica y estado_envio con mayúsculas inconsistentes.
- **items_orden.csv:** producto y categoria con capitalización irregular, precio_unitario con ambigüedad en el separador decimal.

1.4 Limpieza

1. **Valores nulos:** La columna telefono se convirtió a tipo Texto para preservar códigos de área con ceros iniciales. Los nulos en teléfono aproximadamente un 21% y email 10% se mantuvieron en lugar de eliminar filas, ya que estos clientes poseen otros datos válidos relevantes para el análisis. Los registros sin segmento asignado se reemplazaron por "Sin Segmento" para evitar valores técnicos vacíos en los reportes.
2. **Normalización de texto:** Se aplicó capitalización uniforme en ciudad_envio, canal_venta, estado_orden, empresa_logistica, estado_envio, producto y categoria. Se realizaron reemplazos para unificar variantes como "Bs As" a "Buenos Aires", manteniendo "CABA" como entidad independiente, y "Oca" a "OCA".

3. **Conversión numérica:** Se asignó tipo Número decimal a `total_orden`, `costo_envio` y `precio_unitario`. La configuración regional del sistema resolvió automáticamente la ambigüedad del separador decimal en `precio_unitario`.
4. **Fechas:** Se unificaron `fecha_alta`, `fecha_orden`, `fecha_envio` y `fecha_entrega` al tipo Fecha estándar, resolviendo los múltiples formatos presentes en los archivos originales.

1.5 Consolidación

Se utilizó ordenes como tabla base, aplicando tres LEFT JOINs sucesivos:

- **JOIN con clientes** (clave `id_cliente`): coincidió con 11.015 de 12.000 filas. Las 985 órdenes sin cliente asociado se conservaron con nulos en los campos correspondientes.
- **JOIN con envíos** (clave `id_orden`): coincidió con 6.630 de 12.000 filas, indicando que el 45% de las órdenes no tiene envío registrado.
- **JOIN con items_orden** (clave `id_orden`): la tabla final pasó de 12.000 a 33.569 filas, ya que cada orden se repite tantas veces como productos contenga. Este comportamiento es esperado y permite analizar los ítems individualmente.

1.6 Columnas derivadas

Se crearon cinco columnas calculadas mediante *Columna personalizada* en Power Query:

- **año_mes:** extraída de `fecha_orden` en formato yyyy-MM para agrupar por período mensual.
- **tiempo_entrega_dias:** diferencia en días entre `fecha_entrega` y `fecha_envio`. Los valores negativos —producto de inconsistencias en las fechas originales— fueron convertidos a null para no distorsionar promedios posteriores.
- **tiene_envio:** valor binario (Sí/No) que indica si la orden tiene envío válido asociado, contemplando tanto la ausencia de fecha como las fechas inválidas detectadas.
- **estado_limpio:** normalización de `estado_orden` mediante `Text.Proper()` para garantizar uniformidad en los valores categóricos.
- **ingreso_calculado:** producto de `precio_unitario` por cantidad, representando el ingreso real por ítem vendido.

1.7 Análisis mediante tablas dinámicas

Se construyeron seis tablas dinámicas sobre la tabla consolidada, derivando en el siguiente análisis

1. ¿Cuántas órdenes hay por ciudad?

Órdenes por ciudad

- Buenos Aires 4.794
- CABA 2.425
- Córdoba 2.439
- Rosario 2.342.
- Total: 12.000

2. ¿Cómo se distribuyen las órdenes según el segmento de cliente?

Distribución por segmento

- Bronze 3.622
- Gold 3.706
- Silver 3.687
- Sin segmento 985. Total: 12.000.
- Distribución pareja entre los tres segmentos principales.

2. ¿Cuál es el total de ingresos?

El total de ingresos es \$992.363.780

3. Aclarar qué columna utilizaste y si encontraste problemas al calcularlo.

Se utilizó $\text{ingreso_calculado} = \text{precio_unitario} \times \text{cantidad}$. Se detectó ambigüedad en el separador decimal de precio_unitario que fue resuelta por la configuración regional del sistema.

4. ¿Cuál es el costo promedio de envío por empresa logística?

Costo promedio por empresa logística

- Correo Argentino \$2.754,97
- OCA \$2.731,65
- Andreani \$2.685,87

6. ¿Cuál es el tiempo promedio de entrega en días?

Tiempo promedio de entrega

- Correo Argentino 4,89 días
- OCA 4,93 días
- Andreani 4,99 días.

7. ¿Cuáles son los 5 productos más vendidos? **Top**


5 productos más vendidos

- Auriculares 19.101
- Notebook 19.018
- Mouse 18.897
- Monitor 18.766
- Teclado 18.578


1.8 Visualización

Se construyeron dos gráficos dinámicos vinculados a las tablas dinámicas:

- **Evolución de Órdenes Mensuales 2022-2024:** gráfico de línea que muestra la cantidad de órdenes por período mensual. Se eligió este tipo por ser el estándar para series temporales, permitiendo identificar picos y caídas de demanda. Se ajustó el eje Y entre 700 y 1.200 para maximizar la legibilidad de las variaciones



- **Órdenes por Segmento de Cliente:** gráfico de barras horizontales que compara el volumen de órdenes entre segmentos.



Parte 2: R para análisis de datos

Aplicar herramientas de análisis de datos en R para procesar, transformar y analizar una base de datos de la Encuesta Trimestral de Ocupación e Ingresos, utilizando el enfoque de trabajo visto en clase con tidyverse (funciones principales) y generando visualizaciones con ggplot.

Dataset individuos:

https://www.estadisticaciudad.gob.ar/eyc/wpcontent/uploads/2026/04/etoi254_base_usuarios.zip

1. Calcular la tasa de actividad, la tasa de empleo y la tasa de desocupación a partir de la condición de actividad. Expresar los resultados como porcentajes sobre la población total.

A partir de la condición de actividad registrada en la ETOI del cuarto trimestre de 2025, se calcularon las tres tasas básicas del mercado de trabajo para la Ciudad Autónoma de Buenos Aires. La tasa de actividad, definida como el cociente entre la Población Económicamente Activa (PEA) y la población total, alcanzó el 57,2%. La tasa de empleo, que relaciona los ocupados con la población total, resultó del 52,3%. La tasa

de desocupación, calculada sobre la PEA, fue del 8,6%. Los tres indicadores son mutuamente consistentes: la diferencia entre tasa de actividad y tasa de empleo (4,9 puntos porcentuales) se corresponde con la proporción de desocupados dentro de la PEA.

2. Analizar cómo varía la tasa de empleo según sexo.

Al desagregar la tasa de empleo por sexo, se observa una brecha de 7,6 puntos porcentuales desfavorable para las mujeres. La tasa de empleo masculina alcanzó el 56,4%, mientras que la femenina fue del 48,8%. El denominador utilizado en cada caso es el total de la población del grupo respectivo, lo que permite comparar tasas netas sin que la composición demográfica distorsione el resultado.

3. Calcular el ingreso promedio de la ocupación principal según nivel educativo. Considerar únicamente a las personas ocupadas.

El análisis se restringió a personas ocupadas con ingreso laboral declarado mayor a cero, con el fin de excluir casos de trabajo familiar sin remuneración que podrían sesgar los promedios a la baja. Los resultados muestran una relación positiva entre nivel educativo e ingreso promedio mensual: el ingreso mínimo corresponde al nivel primario incompleto o menos, con \$853.619, y asciende progresivamente hasta secundario completo, nivel más alto con casos válidos en el dataset, \$2.205.411. Esta asociación es consistente con la teoría del capital humano y con los patrones habitualmente observados en el mercado laboral de CABA.

4. Analizar la distribución de los ocupados según categoría ocupacional (por ejemplo: asalariado, cuenta propia, etc.). Calcular proporciones.

Entre las personas ocupadas, la categoría predominante es la de asalariado, que concentra al 72,3% del total. Le sigue el trabajo por cuenta propia con el 22,3%, los patrones con el 5,1% y los trabajadores familiares sin remuneración con el 0,3%. Esta distribución es característica de una economía urbana terciaria como la de la Ciudad de Buenos Aires, con alta formalización relativa y escaso peso del trabajo independiente no remunerado.

5. Analizar la brecha de ingresos entre varones y mujeres. Calcular el ingreso promedio por sexo (solo ocupados) y representarlo en un **gráfico comparativo**.

El ingreso promedio de los varones ocupados fue de \$1.783.058, mientras que el de las mujeres fue de \$1.318.021, lo que representa una brecha del 26,1%. Medida por la mediana, la brecha es del 23,1% (\$1.300.000 vs \$1.000.000). Que la brecha sea mayor en el promedio que en la mediana indica que los ingresos más altos están más concentrados en varones

LINK DEL REPOSITORIO DONDE SE ALMACENA EL CÓDIGO

<https://github.com/dominguezmichaela/AnalisisyExploracionDeDatos>